

行业研究访谈提纲：阶跃星辰座舱Agent技术与工程探讨

专家画像：阶跃星辰—汽车部门（座舱AgentOS、超级Eva整车智能体）的算法、技术工程专家。

专家您好：非常感谢专家抽出宝贵时间参与本次行业交流。我们目前正在进行关于汽车智能化与大模型上车的深度行业研究，希望能从您的专业视角，探讨阶跃星辰在智能座舱领域的最新进展，特别是AgentOS和超级Eva的技术与工程实践，行业洞察。

1. 智能座舱Agent

- 能力边界：**在整车电子电气架构中，AgentOS、超级Eva与整车底层和座舱应用的边界如何划分？整车数据读取、控制；操作系统改造；应用生态协同？与硬件Tier1、车厂、应用系统集成分工？
- 功能特性：**AgentOS有哪些功能特性？超级Eva有哪些功能？相比传统交互有哪些不同？新增哪些功能？
- 优势亮点：**相较竞品，如斑马、豆包、讯飞、华为等，有哪些优势和亮点？有哪些代际优势？
- 样板案例：**量产车型搭载AgentOS后的实际用户反馈如何？客户反馈如何？下一步样板车型开发计划？
- 未来规划：**AgentOS未来的演进方向是什么？重点解决什么问题？
 - 超级Eva未来规划？

2. 端/云大模型

- 端侧语言大模型：**端侧语言大模型训练蒸馏基于哪款大模型，Step 3.5 Flash？蒸馏训练的核心目标是什么？具体采用什么参数量级和量化方案？在算力占用、推理延迟、业务场景覆盖上的预期优化指标是怎样的？后续还准备优化规划？
- 端侧多模态大模型：**训练蒸馏基于哪款大模型，Step 3？针对智能座舱场景做了哪些轻量化/蒸馏/量化的关键改造？这些改造对模型多模态能力（语音/视觉/文本）有哪些取舍？
 - 性能瓶颈优化：**从POC验证到量产落地，在端侧的性能瓶颈（延迟、内存等）主要集中在哪些环节？当前有哪些成熟的优化方案？
 - 推理框架与硬件适配：**针对座舱场景的低延迟、高可靠要求，多模态大模型的推理框架做了哪些定制化适配？硬件层面（芯片/内存）有哪些依赖？

3. **实时语音交互模型**：大模型选型，性能与效果取舍？效果、性能指标？优化方案？端云协同？同行对比（如豆包），优劣势？
4. **GUI-Agent大模型**：GUI-Agent大模型选型，性能与效果取舍？效果、资源占用、性能指标？优化方案？端云协同？
5. **动态交互代码生成模型**：这块是否有考虑？大模型选型，性能与效果取舍？效果、资源占用、性能指标？优化方案？端云协同？
6. **云上部署模型**：云侧分别用到哪些大模型？分别的规模、效果及效率指标？评估的依据？关键问题及下一步计划？
7. **算力分配与任务划分**：端侧与云端的算力分配与任务划分是如何规划的？哪些必须在端侧完成，哪些适合云端协同？
8. **技术合作生态**：在汽车智能交互整个方案中，涉及到众多技术，是否有部分技术采用第三方合作模式？目前的技术合作生态是怎样的？比如：
 - a. 语音基座（如语音唤醒、降噪、识别和合成）方面。您认为当前语音基座技术的最大痛点是什么？
 - b. 代码生成等模型。
 - c. 采用或评估过哪些供应商（如思必驰、豆包、千问等）？
9. **模型OTA机制**：端侧大模型迭代节奏是怎样的？版本更新时，如何保障座舱业务的稳定性和兼容性？
 - a. 端侧模型是否有考虑非OTA的方式做大模型问题的修正，还是只能有问题靠模型优化后OTA升级？

3. 上下文与记忆系统

1. **多模态及融合处理**：当前多模态模型除了文本和视觉信息，还会用到哪些多模态信息，是否有规划将汽车各种状态信息融入？
 - a. 信息源有哪些？分为哪几类？
 - b. 多模态输入（语音、视觉、文本、甚至包括触控、车辆传感器数据）在AgentOS架构中是如何融合处理的？是否采用了端侧特征提取+云端语义理解的混合模式？
2. **上下文与记忆存储**：AgentOS的“记忆”是存储为结构化数据还是非结构化文本（如：Markdown）？
 - a. **如何分工**：上下文与记忆如何分工？整个上下文体系是怎样的？
 - b. **上下文存储**：有哪些记忆文件，分别记忆哪些信息？有哪些信息源？
 - c. **记忆存储**：有哪些记忆文件，分别记忆哪些信息？采用什么格式进行存储？结构化还是非结构化存储？有哪些信息源？
 - d. **压缩策略**：长期运行后，上下文和记忆都会不断膨胀，压缩策略是怎样的？

3. **挖掘与提取：**上下文与记忆相关的挖掘和提取方法？
 - a. **车辆原始信号处理：**从哪些原始信号？用什么方法/技术初步提取哪些特征？
 - b. **长期记忆/偏好挖掘：**从哪些信息源或信息特征？用什么方法/技术挖掘哪些偏好或信息？
 - c. **信号处理及挖掘的时机：**什么时机执行这些信息处理与挖掘动作？主动交互的时机？
 - d. **上下文/长期记忆的提取：**上下文与记忆系统内容很多，交互过程中如何做到有选择，上下文/长期记忆的提取与组织方法？
4. **长时记忆与多模态记忆：**当前是否有长时记忆的规划，记忆里面是否会使用多模态信息作为场景记忆的信息？
5. **记忆系统端云如何分工：**端云职责有何不同？如何协同？
 - a. 端侧职责？主要工作？
 - b. 云侧职责？主要工作？云端有多端同步与自成长功能吗？
 - c. 记忆系统端云如何同步？
6. **设计参考推荐：**上下文与记忆是整个系统关键差异，当前发展也很快，有什么样的设计参考建议呢？

4. 主Agent与端云协同

2. **端云分工与协同：**主Agent运行涉及到众多模块，端云如何分工与协同？
 - a. 端侧有哪些模块？云侧有哪些模块？分别的职责？
3. **主Agent：**主Agent的处理流程？
 - a. 上下文如何提取和传入？
 - b. 记忆如何提取与传入？
 - c. Agent / Skill / 工具描述如何筛选和传入？
 - d. 处理延迟是怎样的？
4. **意图理解与规划模型：**部署在云、端，还是两边都有部署？模型选型？效果、资源占用、性能与延迟？评估依据？
5. **端云协同仲裁机制：**端和云的任务处理场景和边界是怎样的？
6. **分发及调用准确性：**上下文、记忆、Agent、Skill、Tool越来越多，如何平衡输入Token规模、效果与响应延迟？
 - a. 怎么保证分发或者工具调用的准确性？
 - b. 新增一个Agent、Skill或工具的策略怎样的？
7. **端云协同快慢策略机制：**云+端架构下是怎么对响应快和慢做设计的，快任务和慢任务是怎么做分类的，依据和边界是什么？

8. 拒识是怎么处理的？

5. Agent、Skill、工具

1. **总体摘要介绍**：概况性介绍？Agent、Skill、工具整体分层情况？设计思路？
2. **端云两侧的工具能力**：工具是大模型与外部互动的重要途径，如：本地车身、车控、导航API等；云端RAG、生态API等。座舱Agent中端侧、云侧分别有哪些工具？量产情况？规划情况？
 - a. 端侧工具？端侧工具的下一步计划？如何增强？
 - b. 云侧工具？
3. **生态接入**：使用的生态信源主要有哪些？是否有深度合作有定制化内容？
4. **端云两侧的Agent**：端侧、云侧分别规划了哪些Agent？Agent端云两侧分工有哪些考量？
5. **第三方智能体接入**：有第三方智能体接入有哪些？第三方智能体与自研分工如何平衡？
6. **新增扩展机制**：新增Agent、Skill、工具。相应的起效机制？
 - a. 越来越多的Agent、Skill、工具，如何保障效果和速度？
 - b. 什么情况下，需要训练模型？训练模式的收益？
 - c. 有哪些避坑经验？推荐设计和思路参考？
7. **配置更新机制**：Agent、Skill、工具配置信息，如何实现端云协同与同步？如：云侧增加Agent、Skill、工具要下发端侧；端侧感知到Tool扩展，如何同步到云端；且不用用户之间，这些还有差别。
8. **多轮对话Agent**：多轮对话填槽场景，是否碰到过效果问题？解决办法是怎样的？上下文如何组织？

6. 训练数据与测试

1. **模型训练数据**：训练所需数据是什么？主要来源是什么？
2. **模型迭代上线**：模型迭代的主要方式，能实现自动化吗？
3. **数据回流迭代**：量产车上，用户及车辆数据，哪些会传到云侧，用户分析和训练？BadCase如何识别与提取？是全量回传还是事件触发？

7. 团队与协作机制

1. **外部协作**：在智能座舱业务上，阶跃星辰与千里科技、吉利研究院的分工边界是怎样的？请举例说明。
2. **团队架构**：阶跃星辰的团队架构是怎样的？座舱AgentOS、超级Eva的团队架构是什么样的？汽车业务各部门分别有多少人，及大致背景？

- a. 阶跃星辰基模团队支撑座舱AgentOS、超级Eva的团队架构是怎样的？团队大概有多少人，团队成员背景？
 - b. 座舱AgentOS、超级Eva的团队架构、团队规模及背景？如：模型训练蒸馏，推理工程；架构、上下文与记忆、主Agent团队；业务Agent、Skill、Tool等。
3. **模型适配与协作模式：**对于座舱场景下的模型优化需求，阶跃星辰基模团队和AgentOS团队如何分工？
- a. 从基模到AgentOS这边上线，模型定制分为哪几个关键步骤？这些步骤分别由哪几个团队主导？
 - b. 如果基模达不到验收标准，通常由哪个团队负责兜底优化？
4. **客户定制优化需求：**对于客户的定制优化需求，AgentOS、超级Eva团队和基模团队如何分工？
-

再次感谢您的支持与分享！期待与您的交流！